

## **Implementação de rotinas de Otimização de Ferramentas de Controle e Redução de Poluição para Rios e Córregos.**

### **Identificação:**

Grande área do CNPq: Ciências Exatas e da Terra

Área do CNPq: Ciência da Computação

Título do Projeto: Planejamento integrado de controle e redução de cargas pontuais e difusas de poluição em bacias hidrográficas

Professor Orientador: Lucia Catabriga

Estudante PIBIC/PIVIC: Luiz Felipe Oliveira Ribeiro

**Resumo:** *Reduzir os índices de poluição em bacias hidrográficas é agenda indispensável no âmbito governamental. Atualmente existem leis que regulamentam a concentração de poluentes em rios. Desejamos encontrar a eficiência mínima de redução de determinados poluentes garantindo o enquadramento de rios na legislação vigente. Abordamos o problema usando técnicas de otimização através de algoritmos evolutivos. Neste trabalho implementamos o algoritmo genético de chaves aleatórias viciadas (BRKGA) considerando o modelo matemático de quantificação de poluentes QUAL-UFMG e um modelo de quantificação de poluição difusa, representando a poluição que chega aos rios através da chuva. O objetivo principal da pesquisa é encontrar a eficiência de remoção de poluentes vindos das fontes pontuais e observar a influência da poluição difusa no montante total de poluição pluvial. Foram feitos diversos testes variando os parâmetros de entrada do BRKGA: tamanho da população, tamanho da elite, função objetivo e critério de parada. Os testes obtiveram resultados positivos, muitas vezes encontrando eficiências próximas da mínima exigida pela lei.*

**Palavras chaves:** Otimização, Algoritmo Genético, BRKGA, Recursos Hídricos, Qualidade de Água

## **1 Introdução**

Desde os primórdios da humanidade, o uso inteligente dos recursos hídricos tem sido fundamental para o desenvolvimento do homem. Na sociedade atual a água continua sendo recurso essencial em vários âmbitos, desde o consumo humano, até atividades associadas ao desenvolvimento econômico do país, como por exemplo, a geração de energia, a produção de alimentos e de bens de consumo. Tudo isso sem mencionar a rica biodiversidade associada a bacias

hidrográficas. Segundo a Agência Nacional das Águas (ANA)<sup>1</sup>, o Brasil possui em seus rios uma vazão disponível total de cerca de 78.600 metros cúbicos de água por segundo (Conejo, 2017), um recurso não-renovável e de preservação fundamental para o desenvolvimento sócio-econômico do país.

Nesse contexto, reduzir os níveis de poluição em rios (também chamados cursos d'água), é um problema de âmbito governamental. A legislação brasileira vigente: o Plano Nacional de Recursos Hídricos, Lei n. 9433/97<sup>2</sup> criou o Enquadramento de Cursos D'água, instrumento de gestão e planejamento no qual os rios são categorizados em classes de acordo com o seu uso. Essas classes apresentam valores de parâmetros de qualidade de água admissíveis para os usos a qual são destinados. Em suma, usos mais nobres como abastecimento público e dessedentação de animais devem apresentar uma concentração reduzida de substâncias poluentes quando comparadas aqueles curso d'água destinados a usos menos nobres, como a navegação.

Em síntese, deseja-se encontrar o menor percentual de tratamento de efluentes domésticos que satisfaça os critérios de uso fixados na legislação ambiental vigente, garantindo que o rio se enquadre em uma determinada classe de qualidade de água (de acordo a necessidade do usuário). Este problema pode ser modelado com um problema de otimização combinatória. A literatura cita inúmeras abordagens computacionais para este tipo de problema (Bringer, 2017). Um problema de otimização combinatória é especificado por um conjunto de instâncias sendo um problema de maximização ou minimização (Aarts & Lenstra, 1997).

No contexto da otimização combinatória, uma classe muito importante de algoritmos são os chamados algoritmos evolutivos (ou evolucionários) que se caracterizam pela utilização de analogias a fenômenos presentes na natureza. Os algoritmos evolutivos são mecanismos iterativos que geram a cada iteração, populações de soluções que evoluem em direção a um ótimo (local ou global) até que um determinado critério de parada seja atingido. Como exemplos de algoritmos evolutivos podemos citar o algoritmo genético clássico (Holland, 1975), que se baseia na teoria da evolução das espécies, e o PSO (Particle Swarm Optimization) (Kennedy & Eberhart, 1995) baseado na coletividade observada em diversas populações.

Descrever com precisão o comportamento dos poluentes no curso d'água é fundamental para um método eficiente de otimização. Para esse propósito utilizamos modelos matemáticos, que consistem em abstrações e por conseguinte equações que descrevem eventos físico-químicos presentes na natureza (von Sperling, 2014). Nesse caso as reações químicas que ocorrem quando um poluente entra num curso d'água. Desse modo, investigamos 3 tipos básicos de poluentes: DBO, Nitrogênio e suas frações, Fósforo e suas frações, e também o parâmetro oxigênio dissolvido. O Oxigênio Dissolvido (OD), é um importante parâmetro de caracterização dos efeitos da poluição das águas por despejos orgânicos (von Sperling, 2014). Se um rio não possui OD, esse rio está em estado de anaerobiose, o que ocasiona morte de peixes e de muitos

<sup>1</sup><http://www3.ana.gov.br>

<sup>2</sup><http://www2.mma.gov.br/port/conama/legiabre.cfm?codlegi=370>

outros seres vivos. A Demanda Biológica de Oxigênio (DBO), é um parâmetro que mede a quantidade de matéria orgânica presente no curso d'água, essa matéria orgânica excessiva vem basicamente de despejos domésticos e industriais, e causa o principal problema de poluição das águas, o consumo de oxigênio pelos microrganismos. Assim como a DBO, o Fósforo e o Nitrogênio também são encontrados em despejos domésticos e industriais, e também são substâncias poluentes, o nitrogênio amoniacal inclusive é tóxico para peixes.

Quanto a origem, a poluição pode ser classificada de duas maneiras (Porto, 1995): a poluição pontual, que é aquela lançada no curso d'água de forma direta, como por exemplo, tubulação de esgotos ou efluentes de indústrias, e a poluição difusa, que é aquela que chega aos rios sendo carregada pela chuva. Em geral, poluição pontual possui valores conhecidos, já a poluição difusa é mais complicada de se quantificar dada a natureza estocástica da chuva, o fato de não existir um ponto de origem exata, e a dependência direta de características do solo (Porto, 1995; Prodanoff, 2005). Para tratar essa problemática também existem modelos matemáticos específicos para quantificação de poluição difusa, como por exemplo o SWMM (Prodanoff, 2005).

Neste subprojeto estudamos um sistema composto por três módulos, um modelo de qualidade de água, um modelo para quantificação de poluição difusa e um algoritmo de otimização, com o objetivo de encontrar eficiências de remoção de poluentes para Estações de Tratamento de Esgoto e assim compreender o comportamento destes poluentes nos corpos d'água para ambas fontes de poluição: difusa e pontual.

## 2 Objetivos

Os principais objetivos desse subprojeto de iniciação científica são:

- Estudo e a implementação do modelo de qualidade de água QUAL-UFMG (von Sperling, 2014) aplicado a três poluentes: a DBO (demanda biológica de oxigênio), Nitrogênio e suas frações, Fósforo e suas frações e ao parâmetro oxigênio dissolvido (OD).
- Estudo e implementação dos modelos: Modelo hidrológico do Soil Conservation Service (SCS) e de Concentração Média de Evento (CME) para a quantificação da poluição difusa.
- Estudo de meta-heurísticas, especificamente algoritmos genéticos, e suas aplicações ao problema de redução de poluição em bacias hidrográficas.
- Implementação de estratégias para resolução do problema, tendo sempre em vista os padrões legais de qualidade de água.
- Produção e uso de software livre utilizando a linguagem Python (Lutz & Ascher, 2007) em todas as implementações.

### **3 Metodologia**

O desenvolvimento da pesquisa dividiu-se em três módulos que atuam de maneira integrada para a resolução do problema: o modelo de qualidade de água (QUAL-UFMG); o modelo hidrológico do SCS e o método da CME; e o algoritmo de otimização (BRKGA). Nas próximas seções, cada um desses módulos é discutido.

#### **3.1 Modelo de Qualidade de água QUAL-UFMG**

O Qual-UFMG é um modelo matemático desenvolvido pelo Departamento de Engenharia Sanitária e Ambiental da UFMG, sendo baseado no Qual2e (von Sperling, 2014). Esse modelo recebe como parâmetros de entrada, a localização e a concentração de poluentes de todos os lançamentos no curso d'água. É composto por equações diferenciais ordinárias de primeira ordem, resolvidas numericamente, neste projeto, utilizando o método de Euler (CAMPOS, 2007) – método de passo simples e de primeira ordem que considera uma divisão o domínio em células usando aproximações em série de Taylor para calcular o valor da função em cada célula (CAMPOS, 2007).

Cada fração de um dos poluentes considerados é modelada por uma equação diferencial que tem como solução aproximada uma função associando concentração e tempo. Porém, como estamos interessados na relação da concentração ao longo do curso d'água, utilizamos uma relação simples de velocidade e tempo obtendo a relação de espaço desejada. Uma particularidade interessante do modelo é a dependência entre as equações. Dada essa dependência natural o problema foi modelado através de três sistemas de EDO, que são resolvidos paralelamente. Um sistema modela DBO, um as formas do Nitrogênio e outro as formas do Fósforo, e em função destes é calculado o balanço de OD, visto que estes poluentes interferem no OD disponível no curso d'água.

Os parâmetros de entrada são dependentes de características físicas do curso d'água, como vazão, declividade, temperatura. Muitas vezes se faz necessário atualizar essas constantes célula a célula dentro do método de Euler, o que acrescenta complexidade ao modelo. Quando um poluente é lançado no curso d'água, são aplicadas as chamadas equações de mistura, que consistem em equações que calculam a concentração resultante da entrada de um efluente no rio.

O modelo também é capaz de aplicar reduções percentuais nos lançamentos de poluentes. Essa funcionalidade é imprescindível para o bom funcionamento do algoritmo genético (Seção 3.2).

#### **3.2 Algoritmos Genéticos**

O algoritmo genético aplica princípios da biologia evolutiva na busca por soluções para problemas dos mais variados tipos (Holland, 1975). Nesse algoritmo temos uma população de indivíduos

chamados *cromossomos*. Um cromossomo é a representação de uma possível solução para o problema denominada *genótipo*. Essa representação é decodificada para gerar a solução propriamente dita, chamada de *fenótipo*. A menor unidade de um cromossomo, é o *alelo* ou *chave*. Classicamente os alelos dos cromossomos são números binários (0 ou 1) (Custódio, 2008), e o *decodificador* é sempre específico para o problema de interesse.

O algoritmo inicializa com a criação de uma população com  $n$  cromossomos, gerados aleatoriamente, levando em consideração que não necessariamente o tamanho da população deve ser mantido durante o processo iterativo. Essa população evolui através de três processos: *elitismo*, *cruzamento* e *mutação*. O elitismo consiste em selecionar os indivíduos de maior qualidade. A cada indivíduo é atribuído um valor chamado função de aptidão que é também a função que deseja-se minimizar. Via de regra, os indivíduos com a maior função objetivo tem maior capacidade de sobreviver através das gerações. O cruzamento, que nada mais é que a geração de um novo indivíduo herdando alelos de dois indivíduos pais, escolhidos aleatoriamente. A mutação consiste na inserção de novos indivíduos durante o processo iterativo. Assim, a população na iteração  $(i + 1)$  é sempre dada pelos melhores indivíduos da iteração  $(i)$ , somada a uma quantidade de indivíduos gerada através de cruzamentos, e uma quantidade de indivíduos mutantes, que nada mais são que novos indivíduos aleatórios, inseridos geração a geração.

As iterações também podem ser chamadas de gerações, uma vez que a cada nova iteração uma nova população baseada na população da iteração anterior é gerada. A população evolui até que um critério de parada pré-estabelecido seja atingido. Como exemplo de critério de parada pode ser considerado o número máximo de iterações ou um número de iterações sem melhora na solução. Ao final do processo é retornado o cromossomo com melhor função de aptidão.

Muitos fatores influenciam no bom desempenho de um algoritmo genético, como por exemplo a escolha dos pais, a escolha dos alelos no cruzamento, a quantidade de indivíduos advindos de cada processo na próxima geração, o critério de parada, a função de aptidão e como ela está implementada, o número de indivíduos na população.

Existem na literatura, varias implementações para o GA, este trabalho considera o algoritmo genético de chaves aleatórias viciadas, ou do inglês BRKGA (Gonçalves & Resende, 2011) detalhado na Seção 3.2.1.

### **3.2.1 Biased Random-Key Genetic Algorithm (BRKGA)**

O algoritmo genético de chaves aleatórias viciadas, proposto por (Gonçalves & Resende, 2011), tem algumas particularidades quando comparado ao GA clássico. Nesse algoritmo o tamanho  $n$  da população é fixo através das iterações e a cada iteração a população é separada em dois conjuntos: o conjunto elite, no qual estão os melhores indivíduos, e o conjunto não-elite, no qual estão os outros indivíduos. Quando acontece um cruzamento, a escolha dos pais é sempre com pelo menos um pai elite, e o indivíduo filho tem sempre mais chances de herdar alelos do pai elite, por isso o nome "Chaves aleatórias viciadas".

No BRKGA o cromossomo é um vetor de números reais entre 0 e 1, a ser decodificado de acordo com o problema. Como o tamanho da população é fixo, a cada nova geração o conjunto elite é copiado inteiramente e uma fração da nova população é dedicada a cruzamentos no qual são inseridos mutantes. O Algoritmo 1 ilustra um pseudo-código para o BRKGA.

---

**Algorithm 1** BRKGA: Dados  $P, P_e, P_m, n, p_a$

---

```
1: Gere uma população com  $P$  cromossomos aleatórios
2: enquanto Critério de parada não for satisfeito faça
3:   Avalie a Função Objetivo de cada solução na população
4:   Particione a população nos conjuntos Elite e não-Elite
5:   Inicialize a população da próxima geração
6:   Gere um conjunto com  $P_m$  mutantes aleatórios
7:   Adicione o conjunto de mutantes a população da nova geração
8:   Copie o conjunto Elite para a próxima geração
9:   para  $i \leftarrow 1$  até  $(P - P_m - P_e)$  faça
10:     Escolhe o pai  $a$  dentro do conjunto elite
11:     Escolhe o pai  $b$  dentro do conjunto não elite
12:     para  $j \leftarrow 1$  até  $n$  faça
13:       Escolhe o alelo do filho, com probabilidade  $p_a > 0.5$  de ser o do pai Elite
14:     fim para
15:     Adicione o filho a população da nova geração
16:   fim para
17: fim enquanto
18: devolve Melhor solução encontrada
```

---

### 3.3 O BRKGA aplicado ao problema de minimização de poluição

A seguir ilustramos as particularidades adotadas ao aplicar o BRKGA ao problema de encontrar eficiências. São apresentadas as restrições, a representação, as funções objetivo, e os critérios de parada

#### 3.3.1 Restrições

As restrições como o próprio nome diz são características específicas do problema que restringem o domínio de busca do algoritmo. Nesse caso, trata-se dos valores máximo que se deseja que permaneça no corpo d'água. Segundo a legislação brasileira, elas são dadas para diferentes classes de qualidade, sendo a classe escolhida para estas simulações, a Classe 2 (von Sperling, 2014). Na Classe 2 as seguintes restrições devem ser consideradas:

- a concentração de DBO no rio não pode ultrapassar  $5mg/L$  em nenhum ponto;

- a concentração de OD não pode ser inferior a  $5mg/L$  em nenhum ponto;
- a eficiência mínima de remoção de uma ETE não pode ser menor que 60 por cento;
- a concentração de DBO do poluente lançado no curso d'água não pode passar de  $120mg/L$ .

Soluções que não atendem as restrições, denominadas inválidas, não são inseridas na população, não importando o momento em que são geradas. Assim, toda vez que uma nova solução é gerada, seja por cruzamento ou por mutação, são verificadas as restrições. A verificação é realizada através de uma chamada ao modelo de qualidade de água QUAL-UFMG, já que para ser enquadrado corretamente, deve-se verificar a concentração dos poluentes em todo o rio. Toda vez que uma solução inválida é gerada, ela é simplesmente descartada e uma nova solução é gerada, até que se encontre uma solução válida.

### 3.3.2 Representação

Como dito anteriormente um cromossomo é uma representação de uma possível solução para o problema. Escolher de maneira inteligente essa representação é muito importante para o bom funcionamento do BRKGA, isso porque, o decodificador que transforma essa representação na solução propriamente dita pode ser caro computacionalmente, pois as soluções podem ser muito difíceis de representar, como nesse trabalho, onde o genótipo é uma função.

Por definição as chaves do BRKGA são números reais de 0 a 1. Desse modo, na representação utilizada, cada chave do cromossomo representa uma eficiência de remoção. Por exemplo, o cromossomo  $[0.60, 0.60, 0.60, 0.60]$  representa 4 lançamentos de efluente, e para cada um desses lançamentos deve-se ter uma remoção de 60 por cento.

Para decodificar essa solução, é necessário fazer uma chamada ao QUAL-UFMG, uma vez que a saída do BRKGA deve indicar que as restrições de concentração foram atendidas.

### 3.3.3 Funções objetivo

Nesse trabalho foram usadas 4 diferentes Funções Objetivo (FO). A FO mais simples, apresentada por Reis & Mendonca (2015), tem por objetivo minimizar o conjunto de  $n$  eficiências:

$$\min|F(x)| = \sum_{i=1}^n E(i) \quad (1)$$

sendo  $E(i)$  a eficiência do  $i$ 'ésimo tratamento de efluente.

As demais FO's incluídas nessa trabalho tem por objetivo inserir medidas de equidade, que visam distribuir de maneira homogênea as eficiências ao longo dos lançamentos. A FO (2) pressupõe que no início do rio a vazão é menor, e por conseguinte há uma menor capacidade de diluição por parte do corpo d'água (Bringer, 2017):

$$\min|F(x)| = \sum_{i=1}^n \sum_{j=i+1}^n \left| \frac{COe(i).DBOr(i)}{E(i).Qr(i)} - \frac{COe(j).DBOr(j)}{E(j).Qr(j)} \right| \quad (2)$$

onde  $COe(i)$  é a carga bruta de efluente no  $i$ 'ésimo lançamento,  $DBOr(i)$  é a concentração de DBO no rio no ponto imediatamente antes do lançamento e  $Q(i)$  é a vazão imediatamente antes do  $i$ 'ésimo lançamento. Na FO (2) a medida de equidade está representada pela subtração da expressão de todos os lançamentos  $j$  que estão depois de  $i$ . A FO (2) apresentou tendências em superestimar a primeira eficiência de remoção, referente a primeira contribuição de fonte pontual. Outra característica importante da FO (2) é a presença da vazão, que parte da ideia de que uma maior vazão gera invariavelmente uma menor concentração de poluente.

A terceira e quarta FO's são consideravelmente similares (Reis et al., 2016):

$$\min |F(x)| = \sum_{i=1}^n \left| \frac{COe(i)}{\bar{COe}} - \frac{E(i)}{\bar{E}} \right| \quad (3)$$

$$\min |F(x)| = \sum_{i=1}^n \left| \frac{COe(i)}{E(i)} - \frac{\bar{E}}{\bar{COe}} \right| \quad (4)$$

onde a barra superior indica os valores médios das grandezas. Nessas funções a medida de equidade está no uso da carga e eficiência médias, resultando em maiores eficiências para contribuições de poluição pontual que apresentem maiores cargas.

### 3.3.4 Critérios de Parada

O critério de parada nada mais é do que a condição na qual o algoritmo para de fazer iterações. É uma medida muito importante, pois quanto mais fazemos iterações, maior o custo computacional, em contrapartida, se fizermos poucas iterações, podemos não encontrar uma solução com boa qualidade.

Nesse trabalho foram testados vários critérios de parada, A seguir destacamos 4 que apresentaram empiricamente os melhores resultados:

- Critério 1: 5 iterações sem melhora na melhor solução.
- Critério 2: A FO média do conjunto elite melhora menos do que uma tolerância pré estabelecida.
- Critério 3: 10 iterações sem que a eficiência de remoção média melhore mais que 1%.
- Critério 4: O desvio padrão da FO da população é menor que uma tolerância pré estabelecida.

O Critério 2 calcula a cada iteração a média aritmética das FO's do conjunto elite, e quando essa média melhora menos que uma tolerância prefixada, o critério é atingido. O Critério 3 calcula a eficiência média de remoção da melhor solução, e quando essa eficiência fica 10 iterações melhorando menos que 1% o critério é atingido. O Critério 4 calcula o desvio padrão, usando como amostra o conjunto de todas as FO's da população, e quando o desvio é menor do que a tolerância, o critério é atingido.



### **3.4 Modelagem da poluição difusa: Modelo Hidrológico Soil Consevation Service (SCS) e CME**

Durante eventos de precipitação parte da água da chuva não consegue penetrar no solo e escoar sob a superfície da bacia hidrográfica, atingindo os curso d'água e aumentando sua vazão, este fenômeno é chamado de escoamento superficial (von Sperling, 2014). Durante o escoamento superficial ocorre um processo de lavagem da superfície da bacia hidrográfica e consequentemente a lixiviação e carreamento de vários poluentes que são encaminhados para os cursos d'água poluindo-os (Prodanoff, 2005).

Sendo assim para estabelecer a ação da poluição difusa em bacias hidrográficas se faz necessário quantificar o valor do escoamento superficial e os valores destas cargas poluentes que são geradas nestes eventos de chuva. Para determinar os valores de vazão de escoamento superficial resultantes destes eventos de precipitação foi implementando em linguagem python o modelo hidrológico do Soil Conservation Service (Santos, 2010) e para estabelecer a carga resultante destes eventos, valores típicos de concentração de poluentes associadas a diferentes tipos de uso do solo foram levantados na literatura.

O modelo hidrológico permite estimar o escoamento superficial causado por uma determinada chuva em uma bacia hidrográfica através dos dados de tipo de solo e cobertura vegetal, estamos interessados em descobrir a vazão total que chega ao rio a partir de uma chuva. Para quantificação da carga de poluentes, a proposta foi usar o método da Concentração Média do Evento (CME) (Prodanoff, 2005), que como o próprio nome sugere, reflete a concentração média de um poluente durante uma chuva específica para diferentes usos do solo.

## **4 Resultados e Discussão**

Para efeito de testes foi realizado um estudo de caso da bacia hidrográfica do rio Pardo. Esse rio nasce em Ibatiba-ES e é um importante tributário do rio Itapemirim, localizado no sul do estado do Espírito Santo (Bringer, 2017). Em sua bacia hidrográfica estão inseridas partes dos municípios de Ibatiba, Irupi, Lúna, Muniz Freire e Lajinha (MG) – compreendendo área de drenagem de cerca de 611 Km quadrados com uma extensão de 57,9 Km (Bringer, 2017). Escolhemos essa bacia em virtude dos trabalhos já realizados no PPGEA/UFES como (Bringer, 2017) e (Reis & Mendonca, 2015). No Rio Pardo existem basicamente cinco contribuições, sendo três delas vindas de rios que desaguam no Rio principal, o ribeirão São José, o rio Pardinho e o ribeirão Perdição, e dois lançamentos de esgotos domésticos provenientes das sedes dos municípios de Ibatiba e Lúna. Desejamos encontrar a eficiência de remoção de DBO para cada um desses lançamentos, ou seja, nosso cromossomo tem tamanho 5. Essas contribuições estão esquematizadas na Figura 1 (Bringer, 2017).

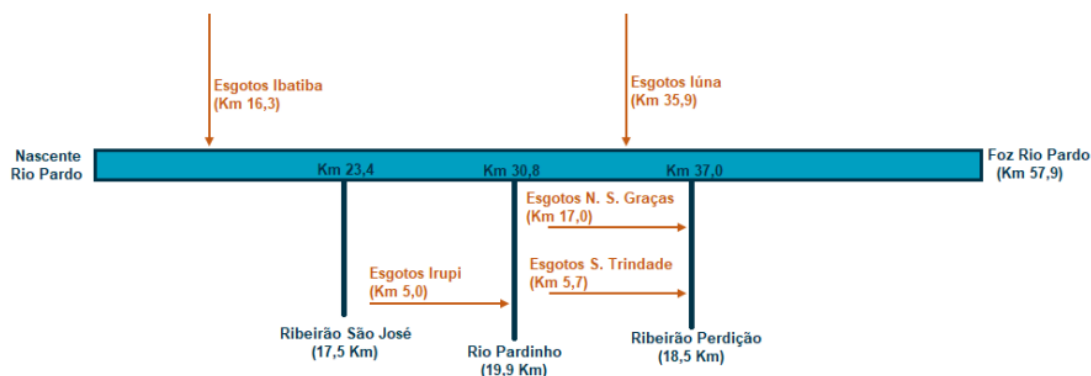


Figura 1: Diagrama Unifilar da Bacia do Rio Pardo - Adaptada de Bringer (2017)

Na Tabela 1 estão indicados os valores de entrada para o QUAL-UFMG, ou seja, os valores de concentração e vazão dos efluentes lançados no rio Pardo, incluindo os rios que desaguam nele:

Tabela 1: Dados de entrada para os testes - Representam as entradas de Poluentes no Rio Pardo  
- As concentrações são dadas em ( $mg/L$ ), e a vazão em ( $m^3/s$ )

Nome	DBO5	OD	N Orgânico	Amônia	Nitrato	Vazão
Efluente 1	400,0	0,0	30,0	50,0	0,0	0,0243
São José	2,4139	6,9947	0,7008	1,6189	0,1729	0,6174
Pardinho	2,4866	6,890	0,8071	1,9106	0,2437	0,7073
Efluente 2	400,0	0,0	30,0	50,0	0,0	0,0199
Perdição	2,7937	6,9406	0,7319	1,6849	0,18	0,6537

## 4.1 Testes Realizados

Foram realizados 12 testes, no qual variamos: a função objetivo, o número de mutantes, o tamanho do conjunto elite e o tamanho da população. Para avaliar o comportamento do BRKGA segundo cada critério de parada, todos os testes foram executados até o número máximo de iterações visando observar em qual ponto da execução aconteceria a parada por cada critério. A discretização para o método de Euler foi feita utilizando células de 100 metros, o número máximo de iterações igual 100 e a tolerância para os critérios de parada foi fixada em  $10^{-4}$ . A Tabela 2 mostra os dados de entrada do BRKGA.  $P$  é o tamanho da população,  $N_e$  é a proporção de indivíduos no conjunto elite,  $N_c$  é a proporção de indivíduos vindo de cruzamento e  $N_m$  é a proporção de mutantes.

Tabela 2: Parâmetros de entrada do BRKGA no testes realizados

Teste	FO	$N_e$	$N_c$	$N_m$	$P$
1	(2)	0,3	0,6	0,1	100
2	(2)	0,3	0,6	0,1	1000
3	(2)	0,1	0,6	0,3	100
4	(1)	0,3	0,6	0,1	100
5	(1)	0,3	0,6	0,1	1000
6	(1)	0,1	0,6	0,3	100
7	(3)	0,3	0,6	0,1	100
8	(3)	0,3	0,6	0,1	1000
9	(3)	0,1	0,6	0,3	100
10	(4)	0,3	0,6	0,1	100
11	(4)	0,3	0,6	0,1	1000
12	(4)	0,1	0,6	0,3	100

## 4.2 Resultados obtidos

A Tabela 3 mostra todas as eficiências encontradas nos testes realizados para cada lançamento. Os lançamentos são nomeados de L1 a L5, seguindo a extensão do rio, sendo que o lançamento L1 é o mais próximo a nascente, e o L5, o mais próximo ao mar.

Tabela 3: Eficiências de remoção de DBO encontradas nos testes realizados

Teste	L1	L2	L3	L4	L5
1	98,86 %	98,79 %	60,04 %	70,09 %	70,25%
2	99,00 %	98,79 %	60,02 %	70,00 %	72.53 %
3	98,95 %	98,22 %	60,10 %	70,22 %	67,87 %
4	71,45 %	60,79%	60,16 %	70,3 %	60,00 %
5	71,25 %	60,06 %	60,01 %	70,02 %	60,02 %
6	71,30 %	60,31 %	60,29%	70,25%	60,52%
7	98,78 %	60,82 %	60,16%	98,82 %	60,35%
8	98,98 %	60,05 %	60,05 %	98,93%	60,09%
9	98,76 %	60,29 %	60,59 %	98,72 %	60,12%
10	98,71 %	60,15%	60,31 %	98,94 %	60,08 %
11	98,99 %	60,01%	60,03 %	98,96 %	60,03 %
12	98,94 %	60,25 %	60,05 %	98,91 %	61,01 %

A FO (2) usada nos testes 1, 2 e 3, obteve os piores resultados dentre os testes, ou seja, en-

contraram as eficiências mais altas. Já a FO (1), testes 4,5 e 6, obteve os melhores resultados, As FO (3) e (4), testes 7 a 12, obtiveram resultados intermediários. Para essa bacia, os melhores resultados foram obtidos pela FO mais simples, isso ocorreu pois se trata de um rio pequeno e rápido, o que faz com que as medidas de equidade propostas pelas FO (2),(3) e (4) acabem superestimando o valor de várias eficiências. Em termos de Engenharia ambiental, os resultados encontrados pela FO (1), são ótimos, pois temos eficiências próximas de 60% que é o mínimo exigido por lei. Uma observação importante sobre as FO (3) e (4) é que elas encontram valores maiores, até próximos de 100%, nos lançamentos L1 e L4, que são justamente os lançamentos de esgoto direto, essa particularidade pode ser interessante de acordo com o objetivo do Gestor ambiental. O aumento no tamanho da população e a variação no tamanho dos conjuntos do BRKGA não gerou mudança significativa no resultado final, em termos das eficiências, não chegou a 1% médio em nenhum dos casos.

A Tabela 4 mostra o número de iterações no qual cada critério de parada foi atingido. Podemos perceber que embora a solução final encontrada não varie muito, a variação nos parâmetros  $N_e$ ,  $P$  e  $N_m$  influencia diretamente no número de iterações para chegar na solução otimizada. Como esperado os testes com a população de 1000 indivíduos fizeram mais iterações que os testes com a população de 100 indivíduos. Esse fato pode ser facilmente explicado uma vez o espaço de busca aumenta para uma população maior. Em 67% dos testes, o Critério 3 foi o que fez menos iterações, em 41,6% dos testes o Critério 2 foi o que mais fez iterações. Este fato ocorre pois a evolução na eficiência média é suave de uma iteração para outra, mas é significativa quando consideramos todas as iterações realizadas. Podemos observar também, que na maioria dos casos os critérios tem um número de iterações bem próximo.

Tabela 4: Número de iterações realizadas por critério de parada

Teste	Critério 1	Critério 2	Critério 3	Critério 4
1	29	34	34	33
2	26	31	27	48
3	21	20	11	19
4	22	24	27	23
5	35	38	12	38
6	20	19	22	18
7	35	40	16	39
8	32	35	12	75
9	25	23	13	22
10	27	28	23	27
11	41	37	17	55
12	15	13	14	15

Nas Figuras 2 e 3 são mostrados mapas para a bacia do Rio Pardo, respectivamente, com os cenários base e otimizado para a DBO. A concentração desse poluente está dividida em faixas com cores diferentes, sendo que a ordem de grandeza das faixas é diferente para o cenário base (Fig.2) e para o cenário otimizado (Fig. 3). No cenário base, podemos perceber que o pico de concentração desse poluente está em 16,4 mg/L (pintado de vermelho no curso do rio), valor muito acima do permitido por lei para a Classe 2 (von Sperling, 2014) que é de 5 mg/L. Já no cenário otimizado, temos um pico de apenas 2 mg/L (pintado de vermelho no curso do rio), muito abaixo do exigido, o que é um ótimo resultado.

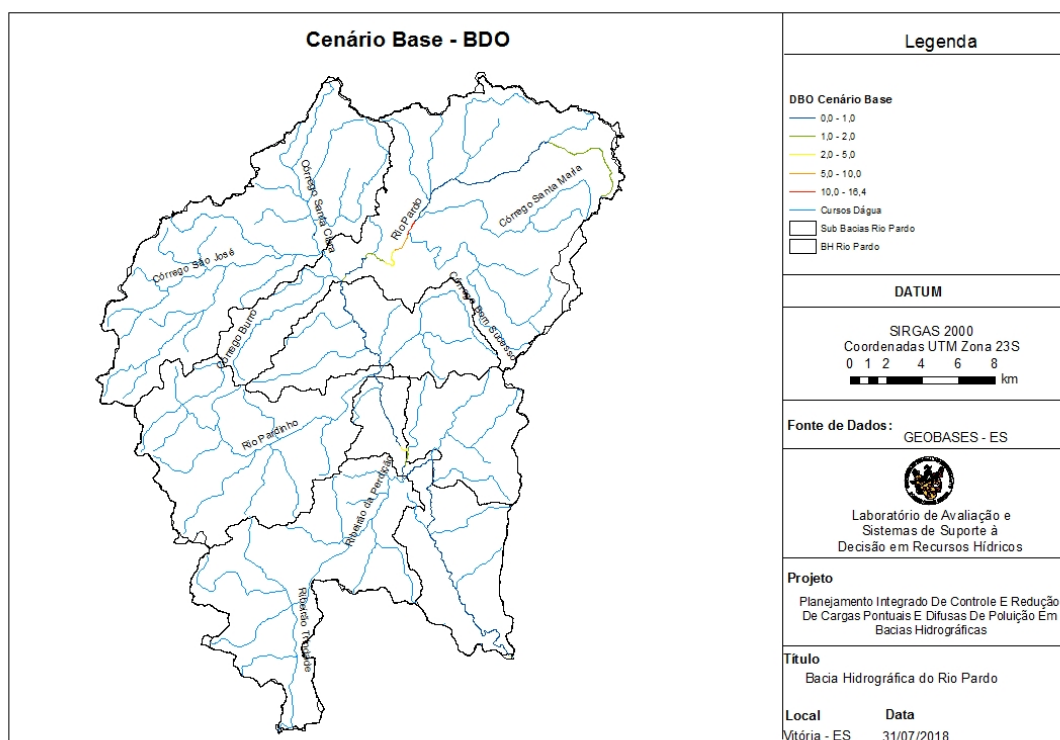


Figura 2: Cenário Base para a Bacia do rio Pardo

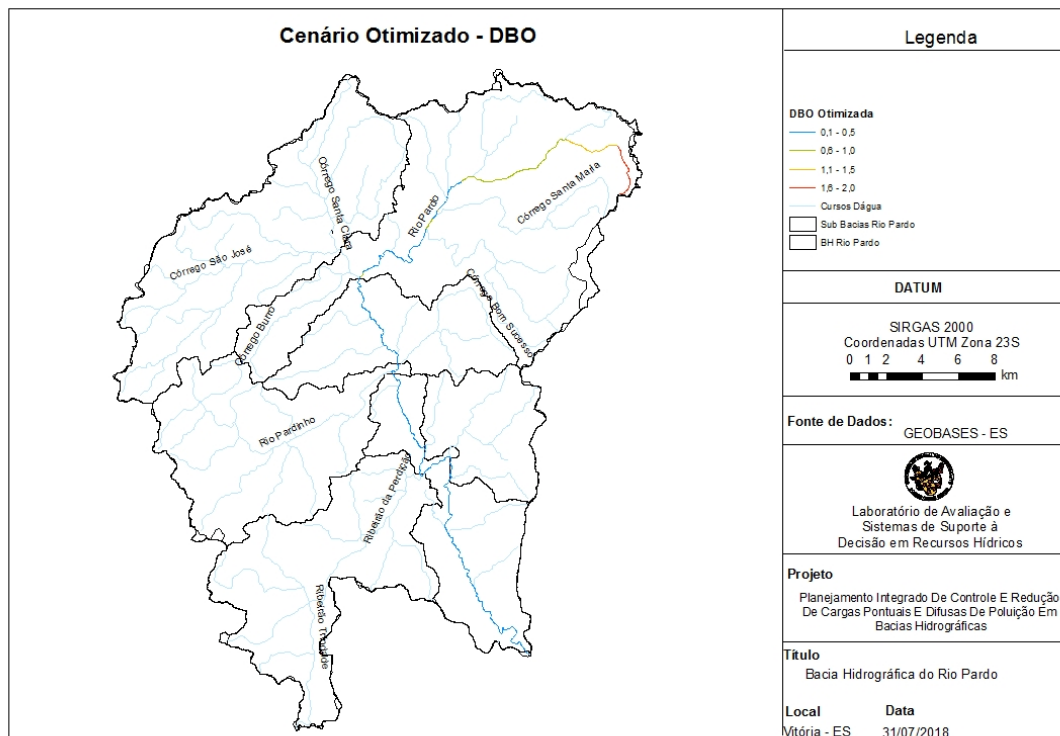


Figura 3: Cenário Otimizado para a Bacia do rio Pardo

## 5 Conclusões

Esse projeto é uma parceria entre o LabHIDRO/DEA/UFES e o LabOtim/DI/UFES, onde adquiriu-se muito conhecimento com relação ao problema da minimização de poluição e suas técnicas de resolução considerando métodos de otimização combinatória e implementações na linguagem Python. Esse projeto está sendo continuado através da participação no PIBIC 2018-2019.

O BRKGA obteve ótimos resultados no tratamento da poluição pontual, mostrando-se muito sensível na escolha da função de aptidão. O modelo de poluição difusa teve sua implementação iniciada, mas não finalizada nesse projeto, sendo assunto do novo projeto aprovado pelo edital PIBIC 2018/2019.

Como metas futuras destacamos: finalização do modelo de poluição difusa; desenvolvimento de uma interface gráfica e consequentemente de um sistema de suporte a decisão; estudo de novas funções objetivo, de novos critérios de parada e possivelmente, de novas meta-heurísticas para o problema. Desejamos investigar também, técnicas para minimizar as cargas de poluição difusa em bacias hidrográficas.

## Referências

- Aarts, E. & Lenstra, J. K., Eds. (1997). *Local Search in Combinatorial Optimization*. New York, NY, USA: John Wiley & Sons, Inc., 1st edition.
- Bringer, L. M. (2017). Seleção de sistemas de tratamento de esgotos no Âmbito de bacias hidrográficas a partir do emprego de modelagem de qualidade, otimização e da análise multi-objetivo. Dissertação (Mestrado em Engenharia Ambiental). Universidade Federal do Espírito Santo.
- CAMPOS, F. F. (2007). *Algoritmos numéricos*. Rio de Janeiro: LTC.
- Conejo, J. G. L. (2017). *Conjuntura dos recursos hídricos no Brasil 2017: Relatório Pleno*. Technical report, Agência Nacional das Águas.
- Custódio, F. L. (2008). *Algoritmos Genéticos para Predição de AB initio de Estrutura de Proteínas*. PhD thesis, Laboratório Nacional de Computação Científica. Tese de Doutorado em Modelagem Computacional.
- Gonçalves, J. F. & Resende, M. G. (2011). Biased random-key genetic algorithms for combinatorial optimization. *Journal of Heuristics*, 17.
- Holland, J. H. (1975). *Adaptation in Natural and Artificial Systems*. Ann Arbor, MI: University of Michigan Press, 1st edition.
- Kennedy, J. & Eberhart, R. (1995). Particle swarm optimization. In *Proceedings of ICNN'95 - International Conference on Neural Networks*, volume 4 (pp. 1942–1948).
- Lutz, M. & Ascher, D. (2007). *Aprendendo Python*. Porto Alegre: Bookman.
- Porto, M. (1995). *Aspectos Qualitativos do Escoamento Superficial em Áreas Urbanas*. Drenagem Urbana. Editora da UFRGS, ABRH.
- Prodanoff, J. H. A. (2005). *Avaliação da Poluição Difusa Gerada por Enxurradas em Meio Urbano*. PhD thesis, Coordenação dos Programas de Pós-Graduação de Engenharia da Universidade Federal do Rio de Janeiro - COPPE/UFRJ. Tese de Doutorado em Engenharia Civil.
- Reis, J. A. T. & Mendonça, A. S. F. (2015). Seleção de eficiências de tratamento de esgotos a partir da manutenção de equidade entre sistemas de tratamento - uma abordagem para o gerenciamento de bacias hidrográficas. *Revista Brasileira de Recursos Hídricos*, 20.
- Reis, J. A. T., Mendonça, A. S. F., & Santoro, M. C. (2016). Performance evaluation of optimization models in the determination of wastewater treatment efficiencies inside watersheds. *Revista Brasileira de Recursos Hídricos*, 21.
- Santos, L. C. C. (2010). Estimativas de vazões máximas de projeto por métodos determinísticos e probabilísticos. Dissertação (Mestrado em Engenharia Ambiental). Universidade Federal do Espírito Santo.
- von Sperling, M. (2014). Introdução à qualidade das águas e ao tratamento de esgotos. belo horizonte: Departamento de engenharia sanitária e ambiental.